ACÁMICA

¡Bienvenidos/as a Data Science!

Agenda

¿Cómo anduvieron?

Repaso: Clases

Explicación: Scikit-Learn y Transformación de Datos con Scikit-Learn

Hands-on training

Break

Aplicaciones Prácticas

Actividad: Explorando Mis Datos

Cierre

¿Cómo anduvieron?

Repaso: Clases

¿Qué es un objeto?

Un objeto es como un un paquete de variables y funciones que conviene tener agrupados por consistencia y comodidad.

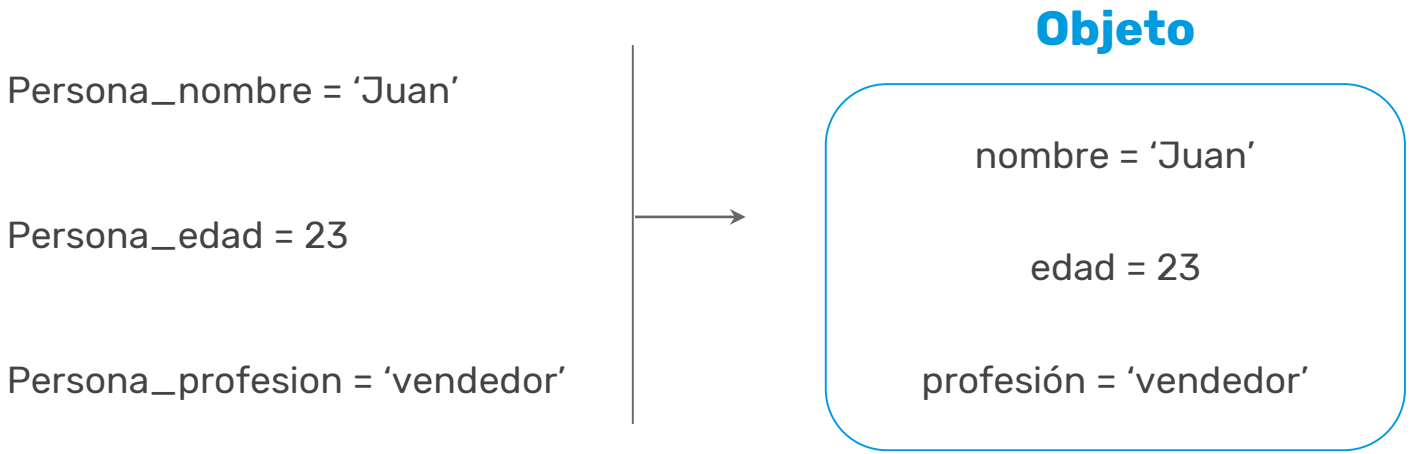

¿Qué es una clase?

Los objetos suelen crearse a partir de unas *plantillas* a las que llamamos clases.

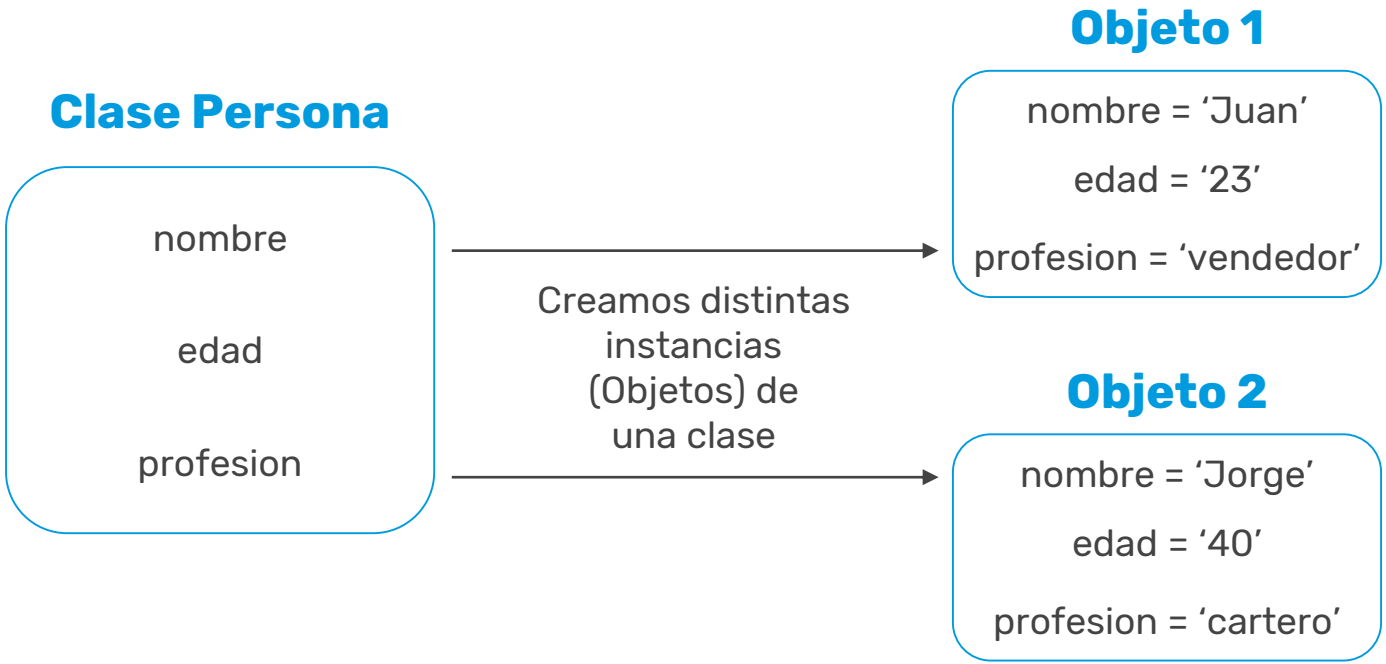

Métodos

Los métodos son funciones propias de una clase. Es decir son funciones que definimos para que actuan sobre un tipo de objeto determinado.

[15]:
```python
class Persona:
    """
    Esta es una clase donde se agregan todos los datos
    respecto a una persona
    """
    def __init__(self, nombre, edad):
        # Todo lo que definamos en __init__ se corre
        # al crear una instancia de la clase
        self.nombre = nombre
        self.edad = edad
    def mePresento(self):
        print("Hola, me llamo " + self.nombre)
```

Métodos: Beneficios

La programación orientada a objetos nos propone una **manera de trabajar** a la hora de escribir nuestro programa.

No sólo es práctico y ordenado, sino que también muchas veces nos ayuda a mantener la consistencia del código.

[1]:
```
class Departamento:
    def __init__(self, calle, altura, sup_total, sup_cubierta):
        self.calle = calle
        self.altura = altura
        self.sup_total = sup_total
        if sup_cubierta < sup_total:
            self.sup_cubierta = self.sup_cubierta
        else:
            self.sup_cubierta = self.sup_total
```

[3]:
```
depto_1 = Departamento('Humboldt',1122,50,455)
depto_1.sup_cubierta
```

[3]:
```
50
```

Scikit-Learn

Clases: Beneficios

Hoy veremos que el formato de clases y métodos propuestos por la librería scikit-learn es muy útil y es el más usado en la comunidad de data science.

SCIKIT learn

- Librería base para Machine Learning en Python
- Podemos usarla para:
  - Preprocesamiento de datos
  - Modelos de Clasificación y Regresión
  - Métricas de Evaluación
- *Fuerza* a seguir un Pipeline
- Excelente documentación

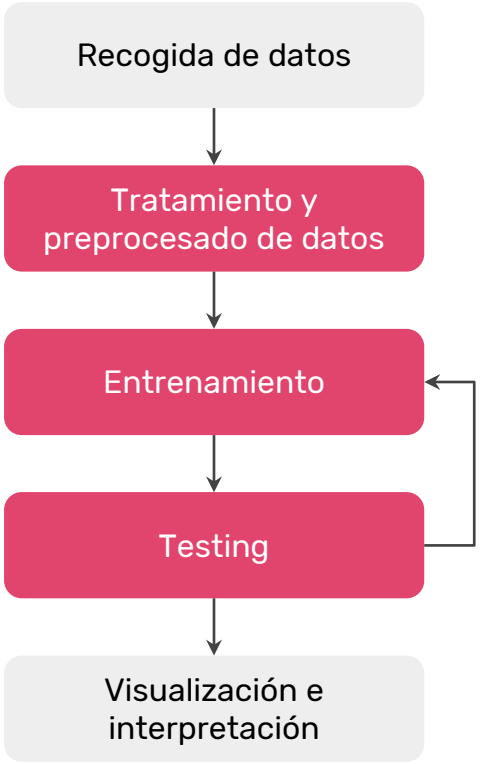

SCIKIT learn: ¿Cómo se usa?

La API (application programming interface) de Scikit-Learn trabaja con **Objetos** y Clases, donde se implementa de manera uniforme métodos y atributos de esos objetos.

Los principales objetos son:

- **Estimadores (*estimators*)** → Tienen un método *.fit*
- **Predictores (*predictors*)** → Tienen un método *.predict*
- **Transformadores (*transformers*)** → Tienen un método *.transform*
- **Modelos (*model*)** → Tienen un método *.score*

¡La mayoría de los objetos pertenecen a más de un tipo!

¡Qué abstracto!

¿Y la explicación en español cómo sería?

Veamos un ejemplo

En general:

1. Se crea un *objeto* con ciertos *parámetros*.
2. Se implementa un método *.fit* que aprende de los datos
3. Se implementa un método *.transform* que transforma los datos.

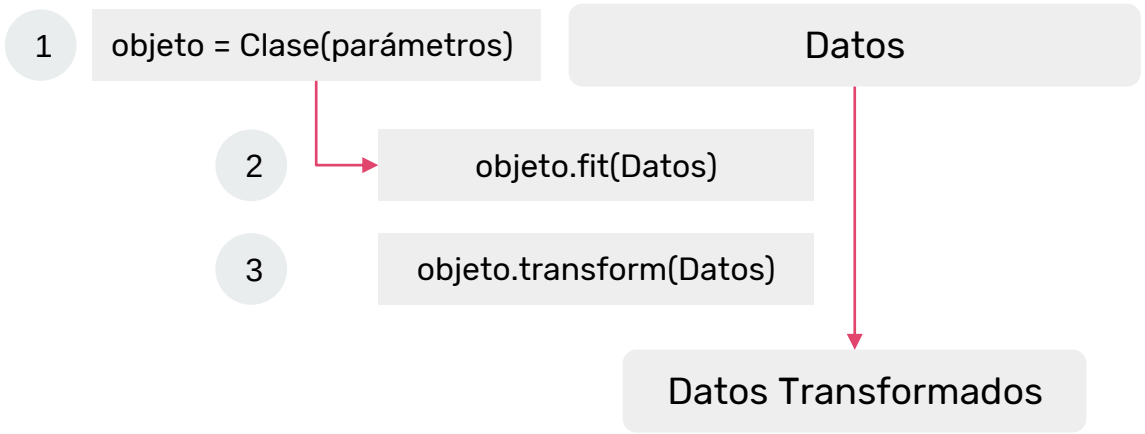

Transformación de Datos con Scikit-Learn

¿Qué aprendimos de los videos?

Para preprocesar datos, Scikit-Learn nos provee de las siguientes herramientas:

Imputer
Para rellenar valores faltantes

OneHotEncoder
Para pasar de variables categóricas a dummys. ¿Sobre qué tipos de datos lo usaremos?

LabelEncoder
Para pasar de variables categóricas a valores numéricos (cuando no necesitemos usar OneHotEncoder).

Notar que cada herramienta es, desde el punto de vista de la programación, una clase. Prestar atención a sus parámetros y sus métodos.

¿Qué aprendimos de los videos?

Nota: algunas funcionalidad de la librería fueron actualizadas desde que se hicieron los videos. Recomendamos ir siempre a la documentación. Por ejemplo, el Imputer ahora está como SimpleImputer en el módulo sklearn.impute

¿Cuándo usar cada una?

La realidad es que usar una u otra librería es una cuestión de gustos, y la mayoría de las veces usamos las dos.

pandas

$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$

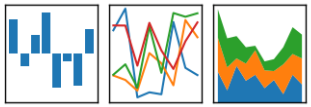

VS

scikit learn

-Generalmente más útil durante EDA

- Generalmente más útil en un flujo de Machine Learning

- Algunas funcionalidades 'aprenden solas' de los datos

Hands-on training

Hands-on training

Instalar Scikit-Learn y luego

DS_Clase_12_TDD_Sklearn.ipynb

¡BREAK!

Ph. Credit: Drew Coffmann

Aplicaciones prácticas

Actividad:
Explorando mis datos

Paso 1 • Elegir un dataset propio o de alguno de los siguientes links

1. **Kaggle:** probablemente el sitio más famoso para obtener datasets (en formatos bastante amigables) y participar de competencias. ¡Recomendamos mirar las competencias!

1. **Datos abiertos de Presidencia Argentina**

1. **Datos abiertos de la Ciudad de Buenos Aires**

1. Y muchos lugares más. Si conocen, no duden en compartir, recomendar, etc.

Paso 2 • Una vez elegido el dataset...

¡Comiencen a explorarlo con las herramientas que aprendimos!

¿Qué preguntas me *gustaría* responder? ¿Qué preguntas *podrán* responder con ese dataset? **¡Lamentablemente, ambas no siempre coinciden!**

TIP: No sientan que se tienen que casar con ese dataset, después si quieren pueden cambiar. Pero si eligen uno que realmente los interpele, van a poder trabajar con esos datos durante la carrera.

Recordatorio sobre condiciones de aprobación

Proyectos • Condiciones de aprobación

Los/as evaluadores/as considerarán una entrega como Aprobada cuando el/la estudiante haya cumplido satisfactoriamente el 100% de los puntos que pide el checklist (aunque no los haya hecho a todos perfectos).

Caso contrario, el/la evaluador/a considerará la entrega como Para rehacer.

Nota: no hay un límite de iteraciones (el/la estudiante puede tener que rehacer su trabajo todas las veces que sea necesario hasta aprobar).

Para la próxima

1. Ver los videos de la plataforma “Transformación de Datos: Detección de Outliers”.

2. Trabajar en la Entrega 02.

3. Seguir explorando el dataset que eligieron.

4. Completar el notebook de hoy si no lo terminaron.

ACÁMICA